

Einführung in die Grundlagen der Numerik

Vorlesungsmitschriften im Wintersemester 2018/19

INHALTSVERZEICHNIS

1	Orthogonalisierungsverfahren	1
1.1	Eigenschaften orthogonaler Matrizen	1
1.2	Anwendung: Lineare Ausgleichsgeraden	1
1.3	Gram-Schmidt-Verfahren	4
1.4	Householder-Transformationen	5
A	Insights from the exercise sheets	7
A.0	Sheet 0	7
	Literatur	9
	Index	11

VORWORT

Diese Vorlesungsmitschriften werden in der Vorlesung *Einführung in die Grundlagen der Numerik* von Prof. Ira Neitzel im Wintersemester 2018/19 an der Universität Bonn angefertigt.

Wir versuchen, diese immer unter <https://pankratius.github.io> zu aktualisieren.

Teile, die von der Vorlesung abweichen, sind in **violett** markiert.

1. ORTHOGONALISIERUNGSVERFAHREN

Betrachte $A \in \text{GL}_n(\mathbb{R})$, wobei A schlecht konditioniert sein kann. Wir wollen ein Gleichungssystem der Form $Ax = b$, mit $b \in \mathbb{R}^n$ gegeben, lösen. Dazu suchen wir eine Orthogonalmatrix $Q \in \text{O}_n(\mathbb{R})$ und eine obere Dreiecksmatrix $R \in \text{M}_n(\mathbb{R})$ mit $A = QR$. Diese Zerlegung von A nennt man **Orthogonalzerlegung**. Dann erhalten wir das äquivalente Problem

$$Ax = b \iff QRx = b \iff Rx = Q^T b.$$

1.1 Eigenschaften orthogonaler Matrizen

Lemma 1.1.1. Sei $Q \in \text{O}_m(\mathbb{R})$ orthogonal. Dann ist auch Q^T orthogonal und es gilt

$$\|Qx\|_2 = \|Q^T x\|_2 = \|x\|_2$$

Beweis. Es gilt

$$\|Qx\|_2^2 = x^T Q^T Q x = x^T x = \|x\|_2^2.$$

Genauso für Q^T . □

Lemma 1.1.2. Sei $A \in \text{GL}_n(\mathbb{R})$ regulär und $Q \in \text{O}_n(\mathbb{R})$ orthogonal. Dann gilt

$$\kappa_2(QA) = \kappa_2(A)$$

Beweis. Die Matrixnorm $\|A\|_2$ ist durch die euklidische Norm induziert, i.e.

$$\|A\|_2 = \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2}.$$

Also folgt aus lemma 1.1.1, dass $\|(\|_2 QA) = \|(\|_2 A)$ gilt.

Betrachte jetzt

$$\|A^{-1}Q^T\|_2 = \max_{x \neq 0} \frac{\|A^{-1}Q^T x\|_2}{\|x\|_2} = \max_{x \neq 0} \frac{\|A^{-1}Q^T x\|_2}{\|Q^T x\|_2} \stackrel{y:=Q^T x}{=} \max_{y \neq 0} \frac{\|A^{-1}\|_2}{\|y\|_2} = \|A^{-1}\|_2$$

□

Also ist für das LGS $Rx = Q^T b : \kappa_2(R) = \kappa_2(A)$. Also hat sich die Kondition des Problems nicht verschlechtert.

1.2 Anwendung: Lineare Ausgleichsgeraden

Betrachte für gegebenes $b \in \mathbb{R}^n$ und $A \in \text{M}_n(\mathbb{R})$ das Optimierungsproblem

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|_2. \tag{O}$$

Dieses Problem ist äquivalent zur Optimierung von $\|Ax - b\|_2^2$.

Seien nun m Tupel $(y_i, f_i) \in \mathbb{R}^2$ ($1 \leq i \leq m$) gegeben. Gesucht ist diejenige affine Gerade $c + dy$ in \mathbb{R}^2 , so dass die Summe der Quadrate der Punkte von der Gerade minimal ist. Wir erhalten also das Optimierungsproblem

$$\min_{(c,d) \in \mathbb{R}^2} \left(\sum_{i=1}^m (c + dy_i - f_i)^2 \right) = \min_{(c,d) \in \mathbb{R}^2} \left\| \begin{pmatrix} 1 & y_1 \\ \vdots & \vdots \\ 1 & y_m \end{pmatrix} \cdot \begin{pmatrix} c \\ d \end{pmatrix} - \begin{pmatrix} f_1 \\ \vdots \\ f_m \end{pmatrix} \right\|_2.$$

Betrachte allgemeiner das Polynom

$$p(y) = \sum_{k=0}^{n-1} a_k y^k.$$

Gesucht sind jetzt die Koeffizienten a_0, \dots, a_{n-1} mit

$$\sum_{j=1}^m (p(y_j) - f_j)^2$$

ist minimal. Schreibe dies ebenfalls als Optimierungsproblem:

$$\min_{a_0, \dots, a_{n-1}} \left\| \begin{pmatrix} y_1^0 & \dots & y_1^{n-1} \\ \vdots & \ddots & \vdots \\ y_m^0 & \dots & y_m^{n-1} \end{pmatrix} \cdot \begin{pmatrix} a_0 \\ \vdots \\ a_{n-1} \end{pmatrix} - \begin{pmatrix} f_1 \\ \vdots \\ f_m \end{pmatrix} \right\|_2^2.$$

End of Lecture 1

Die Existenz der Lösung des Optimierungsproblems folgt aus

$$\lim_{x \rightarrow \infty} \|Ax - b\|_2 \rightarrow \infty,$$

und einer anschließenden Anwendung des Satzes von Weierstraß auf die kompakten Niveaumengen der Abbildung.

Theorem 1.2.1. (Weierstraß) Sei X ein kompakter metrischer Raum und $f : X \rightarrow \mathbb{R}$ eine stetige Abbildung. Dann nimmt f auf X sowohl ein Maximum als auch ein Minimum an.

Sei $f : X \rightarrow \mathbb{R}$, mit $X \subseteq \mathbb{R}$. Dann heißt $x_0 \in X$ ein **lokales Maximum** bzw. **lokales Minimum**, falls es eine Umgebung $x \in V$ gibt, so dass $f(x) \leq f(x_0)$ bzw. $f(x) \geq f(x_0)$ für alle $x \in V$ gilt.

Lemma 1.2.2. Sei $U \subset \mathbb{R}^n$ offen, und $f : U \rightarrow \mathbb{R}$. Angenommen, f hat in $x_0 \in U$ eine Extremstelle und ist in x_0 partiell differenzierbar. Dann gilt

$$\nabla f(a) = 0.$$

Beweis. Betrachte für ein hinreichend kleines $\varepsilon > 0$ und $1 \leq j \leq n$ die Funktion

$$F : (-\varepsilon, \varepsilon) \rightarrow \mathbb{R}, \quad t \mapsto F(x_0 + te_j).$$

Dann hat F in $t = 0$ eine Extremstelle, und es gilt

$$0 = F'(0) = \partial_j f(x_0)$$

□

Betrachte zur Lösung des Optimierungsproblems nun immer die Funktion

$$f : \mathbb{R}^n \rightarrow \mathbb{R}, \quad x \mapsto \frac{1}{2} \|Ax - b\|_2^2.$$

Dann gilt für beliebiges $\bar{x} \in \mathbb{R}^n$

$$\begin{aligned} \langle \nabla f(\bar{x}), h \rangle &= \langle A\bar{x} - b, Ah \rangle \\ &= \langle A^T(A\bar{x} - b), h \rangle \end{aligned}$$

Also gilt für eine Extremstelle \bar{x}

$$\nabla f(\bar{x}) = A^T(A\bar{x} - b) \stackrel{!}{=} 0 \iff \boxed{A^T A \bar{x} = A^T b}. \quad (\text{NE})$$

Zur Lösung des Optimierungsproblems müssen wir also ebenfalls ein Gleichungssystem lösen. Die Gleichung (NE) heißt **Normalengleichung**.

Für $A \in \mathbb{R}^{m,n}$ ist $B := AA^T$ symmetrisch. Weiterhin ist B positiv semi-definit, denn es gilt

$$\langle x, Bx \rangle = x^T Bx = x^T AA^T x = \langle A^T x, A^T x \rangle = \|A^T x\|_2^2 \geq 0.$$

Weiterhin impliziert dies, dass alle Eigenwerte von B größer gleich null sind. Sei dazu λ ein Eigenwert und x ein korrespondierender Eigenvektor von B ,

$$0 \leq \langle Bx, x \rangle = \langle \lambda x, x \rangle = \lambda \|x\|_2^2.$$

Also ist B positiv semi-definit. Angenommen, A hat nun vollen Rang. Dann ist A^T injektiv. Sei x ein Eigenvektor von B zum Eigenwert 0. Dann gilt

$$0 = \langle x, Bx \rangle = \|A^T x\|_2^2 \implies A^T x = 0 \implies x = 0.$$

Also hat B nur positive Eigenwerte. Nach dem euklidischen Spektralsatz [Sch18, S. 20.25] ist B aber diagonalisierbar. Also ist B sogar invertierbar, und die Normalengleichung hat hier jeweils eine eindeutig bestimmte Lösung. Im folgende habe A also immer maximalen Rang. Weil AA^T symmetrisch positiv-definit ist, kann man (NE) mit der Choleskyzerlegung lösen. Es gilt aber $\kappa_2(AA^T) = \kappa_2(A)^2$,

Wie ist die Kondition von A im nicht-quadratischen Fall definiert?

weshalb weitere Lösungsverfahren betrachtet werden müssen.

Dazu definieren wir die **erweiterte Orthogonalzerlegung** von $A \in \mathbb{R}^{m,n}$, mit $m \geq n$ durch

$$A = QR, \quad \text{mit } Q \in O_m \mathbb{R} \text{ und } R = \begin{bmatrix} \hat{R} \\ 0 \end{bmatrix},$$

wobei $\hat{R} \in \mathbb{R}^{n,n}$ eine obere Dreiecksmatrix ist. R heißt in diesem Fall **erweiterte obere Dreiecksmatrix**

Angenommen, eine solche Zerlegung existiert. Dann gilt

$$\begin{aligned} \|Ax - b\|_2^2 &= \|QRx - b\|_2^2 \\ &= \|QRX - QQ^Tb\|_2^2 \\ &= \|Q(Rx + Q^Tb)\|_2^2 \\ &= \left\| \begin{bmatrix} \hat{R} \\ 0 \end{bmatrix} x - \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} \right\|_2^2 \\ &= \left\| \hat{R}x' - y_1 \right\|_2^2 + \|y_2\|_2^2, \end{aligned}$$

für passend gewählte y_1, y_2 . Weil y_2 aber fix ist, reicht es,

$$\left\| \hat{R}x - y_1 \right\|_2^2$$

zu minimieren.

Theorem 1.2.3. Sei $1 \leq n \leq m$ und $A \in \mathbb{R}^{m,n}$, mit $\deg A = n$. Angenommen, A hat eine erweiterte Orthogonalzerlegung. Sei

$$Q^T =: \begin{pmatrix} y_1 \\ y_2 \end{pmatrix},$$

mit $y_1 \in \mathbb{R}^n$ und $y_2 \in \mathbb{R}^{m-n}$. Dann sind äquivalent

- i) $\bar{x} \in \mathbb{R}^n$ löst das Optimierungsproblem (O).
- ii) $\hat{R}x = y_1$.

1.3 Gram-Schmidt-Verfahren

Wir wollen die Existenz einer Orthogonalzerlegung von A zeigen. Dazu verwenden wir [Sch18, S. 11.32]

Proposition 1.3.1. (Gram-Schmidtsches Orthogonalisierungsverfahren) Sei V ein n -dimensionaler euklidischer Vektorraum und (b_1, \dots, b_n) eine geordnete Basis von V . Für $1 \leq i \leq n$ sei

$$V_i := \text{Lin}(b_1, \dots, b_i),$$

die also eine Flagge

$$0 = V_0 \subset V_1 \subset \dots \subset V_n = V$$

bilden. Dann gibt es eine geordnete Orthogonalbasis $(\hat{b}_1, \dots, \hat{b}_n)$ von V , so dass

$$V_i = \text{Lin}(\hat{b}_1, \dots, \hat{b}_i) \tag{*}$$

gilt.

Theorem 1.3.2. Für jede reguläre Matrix $A \in \text{GL}(\mathbb{R})$ existiert eine orthogonale Matrix $Q \in \text{O}_n(\mathbb{R})$ und eine obere Dreiecksmatrix $R \in \text{Mn}$, so dass $A = QR$ gilt.

Beweis. Aus (*) folgt, dass für die Abbildung

$$g : V \rightarrow V, \quad b_i \mapsto \hat{b}_i$$

oben die Koordinatenmatrix bezüglich B in oberer Dreiecksform sein muss. Weiterhin ist g per Definition ein Isomorphismus.

Betrachte nun den konkreten Fall für $A \in \text{GL}_n(\mathbb{R})$. Dann bilden die Spalten von A^{-1} eine geordnete Basis von \mathbb{R}^n . Also gibt es eine obere Dreiecksmatrix g , so dass

$$gA^{-1} = Q,$$

wobei $Q \in \text{O}_n(\mathbb{R})$ orthogonal ist. Dabei haben wir benutzt, dass eine Matrix Q genau dann orthogonal ist, wenn ihre Spalten eine Orthonormalbasis von \mathbb{R}^n bilden [**schroer**]. Damit erhalten wir aber

$$A = Q^{-1}g,$$

und $Q^{-1} \in \text{O}_n(\mathbb{R})$, weil die orthogonalen Matrizen eine Gruppe bilden. □

1.4 Householder-Transformationen

Betrachte für ein fixes $w \in \mathbb{R}^s$ mit $w^T w = 1$ die Abbildung

$$H : \mathbb{R}^s \rightarrow \mathbb{R}^s, x \mapsto x - 2ww^T x.$$

Die Abbildung H heißt **Householder-Spiegelung**.

Proposition 1.4.1. *Für ein solches H gilt*

$$i) \quad H^T = H$$

$$ii) \quad H^2 = E_s,$$

also ist H insbesondere eine orthogonale Matrix, $H \in \text{O}_s(\mathbb{R})$.

Beweis. i) $H^T = (E_s - 2ww^T)^T = E_s^T - 2(w^T)(w^T) = E_s - 2ww^T = H$

ii) Es gilt $\mathbb{R}^s = \text{Lin}(w) \perp (\text{Lin}(w))^\perp$. Weil H linear ist, genügen die folgenden beiden Ergebnisse

$$H(w) = w - 2(ww^T)w = w - 2w(w^T w) = w - 2w = -w,$$

und für $v \perp w$

$$H(v) = v - 2(ww^T)v = v - 2w(w^T v) = v.$$

□

End of Lecture 2

A.0 Sheet 0

Definition A.0.1. Die **Frechet-Ableitung** bezeichnet die gewöhnliche totale Ableitung einer Funktion $\mathbb{R}^n \rightarrow \mathbb{R}$.

Definition A.0.2. Sei $A \in M_n(\mathbb{K})$. Der **Spektralradius** von A ist definiert als

$$\rho(A) := \max\{|\lambda_1|, \dots, |\lambda_n|\},$$

wobei $\lambda_1, \dots, \lambda_n$ die (möglicherweise komplexen) Eigenwerte von A darstellen.

Proposition A.0.3. Sei $M \in M_n(\mathbb{R})$, und

$$\varphi : \mathbb{R}^n \rightarrow \mathbb{R}^n, x \mapsto Mx + c.$$

Dann sind äquivalent:

i) Für den Spektralradius p gilt $p(M) < 1$.

ii) Die Fixpunktiteration

$$x_{k+1} := \varphi(x_k)$$

konvergiert für ein beliebiges $x_0 \in \mathbb{R}^n$.

Solution A.0.2. Es gilt für das in der Aufgabenstellung spezifizierte ψ :

$$\{\text{Eigenwerte von } \psi\} = \lambda + (1 - \lambda) \cdot \{\text{Eigenwerte von } \varphi\},$$

wobei jeweils nur der lineare Teil betrachtet wurde. Nutze nun proposition [A.0.3](#).

Proposition A.0.4. Das Jacobi-Verfahren für die Matrix

$$A = D - L - R$$

konvergiert, falls für die Matrix

$$I_{Jac.} := D^{-1}(L + R)$$

der Spektralradius größer 1 ist. Es konvergiert nicht, wenn der Spektralradius kleiner 1 ist.

Definition A.0.5. Die **Newton-Iteration** ist gegeben durch

$$x_{k+1} := x_k - \frac{f(x_k)}{f'(x_k)}$$

LITERATUR

[Sch18] Jan Schrøer. **Lineare Algebra**. Vorlesungsskript, 2018.

INDEX

Extremstelle, [2](#)

Householder-Spiegelung, [5](#)

Normalengleichung, [3](#)

obere Dreiecksmatrix

erweiterte, [4](#)

Orthogonalzerlegung, [1](#)

erweiterte, [3](#)

Spektralradius, [7](#)